گزارش فنی پروژه: پایدارسازی نوسان آونگ کروی در MuJoCo با DQN و مقایسه با PID

علیرضا رضایی

۸ اسفند ۱۴۰۴

فهرست مطالب

۱ صورت مسئله و هدف کنترلی ۳

۲ مدل‌سازی در MuJoCo بر اساس فایل rope_arm.xml ۳
۱.۲ ساختار کینماتیکی و اجزای فیزیکی ۳
۲.۲ اکچویتور موقعیت و تفسیر سیگنال کنترلی ۴
۳.۲ حسگرهای IMU و تبدیل چارچوب‌ها ۴
۴.۲ پارامترهای عددی شبیه‌سازی ۵

۳ بخش اصلی: فرمول‌بندی یادگیری تقویتی و DQN ۵
۱.۳ فضای حالت/مشاهده (Observation) ۵
۲.۳ فضای کنش و نگاشت کنش به فرمان اکچویتور ۶
۳.۳ اغتشاش اولیه (Force Kick) ۶
۴.۳ تابع پاداش، معیار پایداری و پایان اپیزود ۶
۱.۴.۳ جزء اصلی پاداش: جریمهٔ شتاب افقی ۶
۲.۴.۳ جریمه‌های کمکی: زاویهٔ یاو و نرمی فرمان ۶
۳.۴.۳ پاداش پایداری و خاتمهٔ اپیزود ۶

۴ الگوریتم DQN مطابق پیاده‌سازی شما ۷
۱.۴ Q-learning و معادلهٔ بلمن (رفع خطای شما) ۷
۲.۴ تقریب Q با شبکهٔ عصبی ۷

۳.۴ DQN Double ۷
۴.۴ تابع هزینه (Huber / SmoothL1) ۷
۵.۴ خلاصهٔ هایپرپارامترها ۸

۵ تحلیل نتایج و تفسیر نمودارها (RL) ۹
۱.۵ نمودار پاداش کل اپیزودها ۹
۲.۵ نمودار طول اپیزود ۱۰
۳.۵ نمودار شتاب افقی نهایی ۱۱
۴.۵ ارزیابی زمانی: شتاب افقی IMU ۱۲
۵.۵ ارزیابی زمانی: یاو واقعی و یاو فرمان ۱۳

۶ کنترل PID و تفاوت‌های آن با RL ۱۴
۱.۶ نتایج PID: تحلیل نمودارها ۱۴
۲.۶ تفاوت‌های کلیدی ۱۵

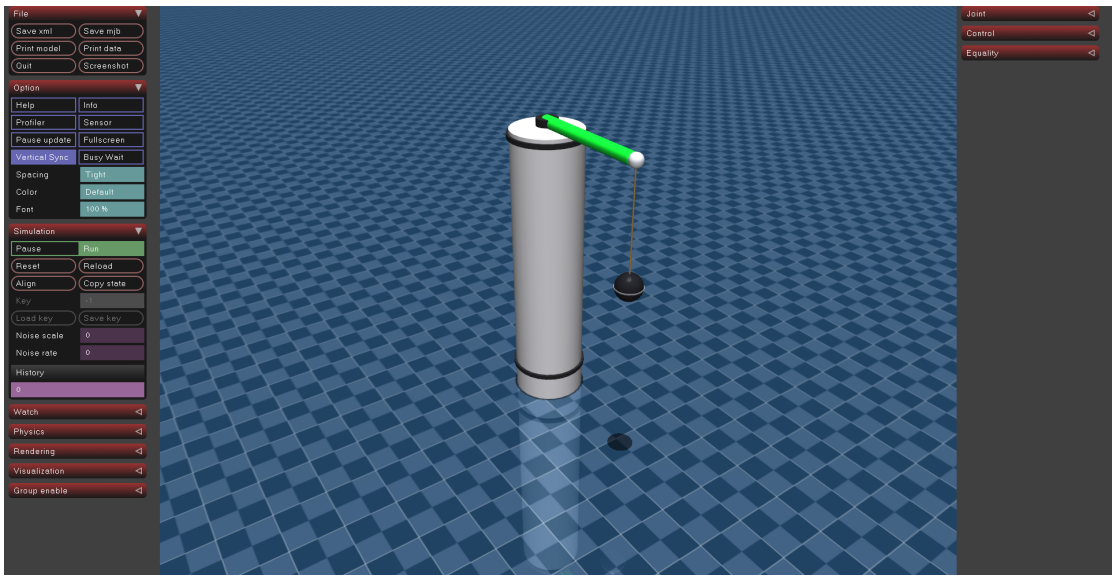
۷ جمع‌بندی ۱۵

۱ صورت مسئله و هدف کنترلی

در این پروژه یک سامانهٔ مکانیکی در محیط MuJoCo مدل شده است که از اجزای زیر تشکیل می‌شود:

- یک ستون ثابت (بدنهٔ stand)،
- یک بازوی افقی سبزرنگ (بدنهٔ green_link) که حول محور عمودی (یاو) می‌چرخد،
- یک کابل/میلهٔ صلب (ژئوم cable) و یک توپ (ژئوم ball) که از انتهای بازو آویزان است (بدنهٔ rope_rigid).

هدف کنترلی: پس از یک اغتشاش اولیه (اعمال نیروی ضربه‌ای به توپ)، با کنترل زاویهٔ یاوِ بازوی سبز، نوسان توپ کاهش یابد و در یک بازهٔ زمانی کوتاه به وضعیت «پایدار» برسد. معیار پایداری در کد شما عمدتاً بر پایهٔ کوچک شدن شتاب افقی توپ (اندازهٔ بردار (a_x, a_y)) تعریف شده است.



شکل ۱: نمای صحنهٔ شبیه‌سازی (تصویر ذخیره‌شده): ستون ثابت، بازوی سبز، کابل و توپ آویزان.

۲ مدل‌سازی در MuJoCo بر اساس فایل rope_arm.xml

۱.۲ ساختار کینماتیکی و اجزای فیزیکی

زنجیرهٔ بدنه‌ها مطابق MJCF به صورت زیر است:

$$world \rightarrow stand \rightarrow green_link \rightarrow rope_rigid.$$

ستون (stand). ستون یک سیلندر با جرم حدود ۴۰ است و ثابت در فضا قرار دارد (بدون مفصل).

بازوی سبز (green_link). بازو شامل یک ژئوم کپسولی به طول تقریبی ۱٫۰ m و جرم ۲٫۰ kg است و با مفصل hinge به نام joint0 حول محور

$$\hat{z} = (0, 0, 1)$$

می‌چرخد. بازهٔ زاویه‌ای این مفصل در XML برابر $[-170^\circ, 170^\circ]$ و میرایی آن damping=3.0 است.

آونگ/کابل و توپ (rope_rigid). بدنهٔ rope_rigid با مفصل ball به نام rope_joint به محل اتصال بازو وصل است و یک ژئوم کپسولی به عنوان کابل/میلهٔ صلب (طول تقریبی ۰٫۹۶ m) و یک ژئوم کروی به عنوان توپ با جرم ۰٫۵ kg در انتها دارد.

۲.۲ اکچویتور موقعیت و تفسیر سیگنال کنترلی

در فایل XML یک اکچویتور از نوع position با مشخصات زیر تعریف شده است:

```
dampratio=1.0) kp=350, joint=joint0, position(name=yaw_pos,.
```

این اکچویتور «گشتاور مستقیم» دریافت نمی‌کند؛ بلکه سیگنال ctrl را به عنوان «زاویهٔ هدف» برای مفصل joint0 در نظر می‌گیرد و با بهرهٔ بالا به دنبال آن می‌رود. محدوده‌ها:

$$\textit{ctrlrange} = [-170^\circ, 170^\circ], \qquad \textit{forcerange} = [-300, 300].$$

بنابراین در تحلیل کنترل (چه RL و چه PID) باید توجه کرد که فرمان نهایی شما «مرجع موقعیت» است و دینامیک سروموتور داخلی MuJoCo نیز روی پاسخ سیستم اثر می‌گذارد.

۳.۲ حسگرهای IMU و تبدیل چارچوب‌ها

در محل توپ یک site به نام imu_site تعریف شده و سه حسگر به آن متصل است:

- accelerometer با نام ball_acc،
- gyro با نام ball_gyro،
- framequat با نام ball_quat.

خروجی شتاب‌سنج در چارچوب محلیِ سایت گزارش می‌شود. در کد شما با ماتریس دوران سایت (site_xmat) به چارچوب جهانی تبدیل می‌شود:

$$\mathbf{a}_W = \mathbf{R}_{W \leftarrow S}\, \mathbf{a}_S.$$

نکتهٔ کلیدی: شتاب‌سنج در MuJoCo معمولاً شتاب «شامل گرانش» را گزارش می‌کند؛ لذا در حالت سکون انتظار داریم

$$\mathbf{a}_W \approx (۰, ۰, -g),$$

و در نتیجه مولفه‌های افقی a_x, a_y نزدیک صفر خواهند بود.

۴.۲ پارامترهای عددی شبیه‌سازی

در option داریم:

$$\Delta t = ۰/۰۰۰۵\ s, \qquad \mathrm{g} = (۰, ۰, -۹/۸۱), \qquad \textit{integrator} = \textit{implicitfast}.$$

در بخش RL از FRAME_SKIP=10 استفاده شده است؛ بنابراین دورهٔ تصمیم‌گیری عامل:

$$\Delta t_{RL} = ۱۰\Delta t = ۰/۰۰۵\ s.$$

۳ بخش اصلی: فرمول‌بندی یادگیری تقویتی و DQN

در این پروژه محیطی به نام BallStabilizeEnv ساخته شده و مسئله به صورت یک فرآیند تصمیم‌گیری مارکوف (MDP) مدل می‌شود:

$$(\mathcal{S}, \mathcal{A}, P, r, \gamma).$$

۱.۳ فضای حالت/مشاهده (Observation)

بردار مشاهده در کد به شکل زیر ساخته می‌شود:

$$\mathbf{o}_t = \left[a_x,\ a_y,\ a_z,\ g_x,\ g_y,\ g_z,\ \tilde{\psi},\ \widetilde{\dot{\psi}}\right]^\top.$$

نرمال‌سازی یاو.

$$\tilde{\psi} = \mathrm{clip}\left(\frac{\psi}{\psi_{\max}}, -۱, ۱\right), \qquad \psi_{\max} = ۱۷۰^\circ.$$

نرخ یاو.

$$\dot{\psi} \approx \frac{\psi_t^{cmd} - \psi_{t-۱}^{cmd}}{\Delta t_{RL}}, \qquad \widetilde{\dot{\psi}} = \mathrm{clip}\left(\frac{\dot{\psi}}{\dot{\psi}_{\max}}, -۱, ۱\right), \qquad \dot{\psi}_{\max} = ۲۴۰^\circ/s.$$

۲.۳ فضای کنش و نگاشت کنش به فرمان اکچویتور

$$\mathcal{A} = \{۰, ۱\}, \qquad \psi^{des} = \psi_t^{cmd} + \begin{cases} -\Delta_\psi & a = ۰, \\ +\Delta_\psi & a = ۱, \end{cases} \qquad \Delta_\psi = ۱/۵^\circ.$$

اعمال محدودیت نرخ (Rate Limit).

$$|\psi_{t+۱}^{cmd} - \psi_t^{cmd}| \le \dot{\psi}_{\max}\, \Delta t_{RL} = ۲۴۰ \times ۰/۰۰۵ = ۱/۲^\circ.$$

۳.۳ اغتشاش اولیه (Force Kick)

$$\mathbf{f}_{kick} = F\,\hat{\mathbf{x}}, \qquad F = ۶۰, \qquad ۰ \le t < ۰/۱۵\ s.$$

۴.۳ تابع پاداش، معیار پایداری و پایان اپیزود

$$a_{xy} = \sqrt{a_x^۲ + a_y^۲}.$$

۱.۴.۳ جزء اصلی پاداش: جریمهٔ شتاب افقی

$$r_{acc} = -\tanh\!\left(\frac{a_{xy}}{s}\right), \qquad s = ۱۰, \qquad r_{acc} \in [-۱, ۰].$$

۲.۴.۳ جریمه‌های کمکی: زاویهٔ یاو و نرمی فرمان

$$r_{yaw} = -۰/۰۵\left(\frac{|\psi|}{۹۰}\right), \qquad r_{\Delta\psi} = -۰/۰۲\left(\frac{|\psi_t^{cmd} - \psi_{t-۱}^{cmd}|}{\Delta_\psi}\right), \qquad r_t = r_{acc} + r_{yaw} + r_{\Delta\psi}.$$

۳.۴.۳ پاداش پایداری و خاتمهٔ اپیزود

$$a_{xy} < ۳/۰ \Rightarrow r_t \leftarrow r_t + ۱.$$

اگر این شرط برای ۴۰ گام متوالی برقرار باشد:

$$r_t \leftarrow r_t + ۲۰۰, \qquad ۴۰ \times ۰/۰۰۵ = ۰/۲\,s.$$

۴ الگوریتم DQN مطابق پیاده‌سازی شما

۱.۴ Q-learning و معادلهٔ بلمن (رفع خطای شما)

$$Q^{\pi}(s,a) = \mathbb{E}_{\pi}\left[\sum_{k=۰}^{\infty} \gamma^k r_{t+k} \,\middle|\, s_t = s, a_t = a\right].$$

$$Q^{*}(s,a) = \mathbb{E}\Big[r_t + \gamma \max_{a'} Q^{*}(s_{t+۱}, a') \,\Big|\, s_t = s, a_t = a\Big].$$

۲.۴ تقریب Q با شبکهٔ عصبی

$$\hat{Q}(\mathbf{o};\theta) = \mathrm{MLP}_{\theta}(\mathbf{o}) \in \mathbb{R}^{۲}.$$

۳.۴ DQN Double

$$a^{\star} = \arg\max_{a'} \hat{Q}(s', a'; \theta), \qquad y = r + \gamma(۱ - d)\hat{Q}(s', a^{\star}; \theta^{-}).$$

۴.۴ تابع هزینه Huber / SmoothL۱

$$\delta = \hat{Q}(s,a;\theta) - y, \qquad \mathcal{L}(\delta) = \begin{cases} \frac{۱}{۲}\delta^{۲} & |\delta| < ۱, \\ |\delta| - \frac{۱}{۲} & |\delta| \geq ۱. \end{cases}$$

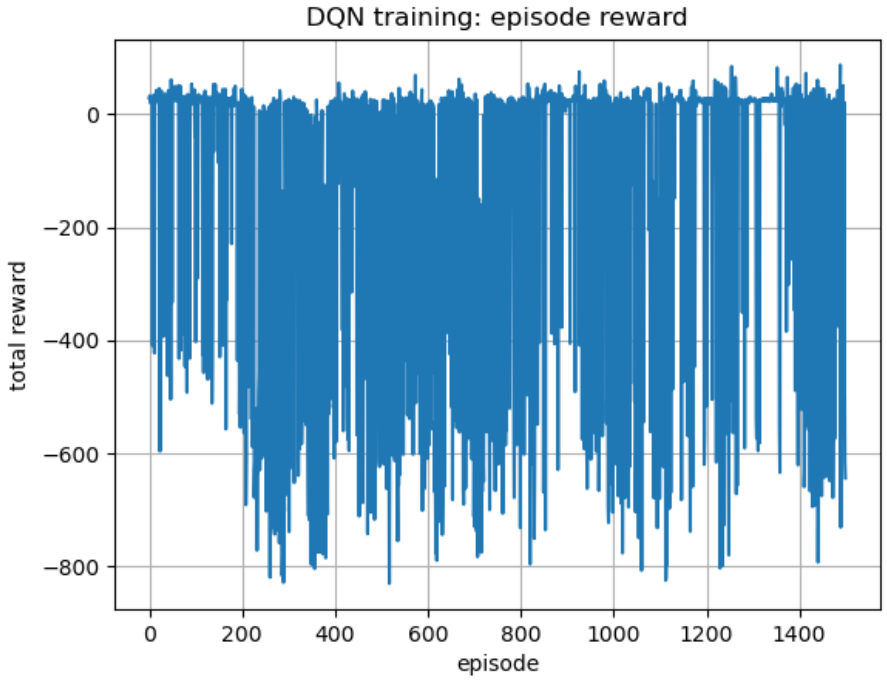
۵.۴ خلاصهٔ هایپرپارامترها

جدول ۱: خلاصهٔ هایپرپارامترهای بخش .*RL*

پارامتر	مقدار
TOTAL_EPISODES	۱۵۰۰
MAX_EP_STEPS	۸۰۰
γ	۹۹.۰
LR	۳×۱۰^{-۴}
BATCH_SIZE	۲۵۶
REPLAY_SIZE	۲۰۰۰۰۰
LEARN_START	۲۰۰۰
TARGET_UPDATE_EVERY	۱۰۰۰
FRAME_SKIP	۱۰

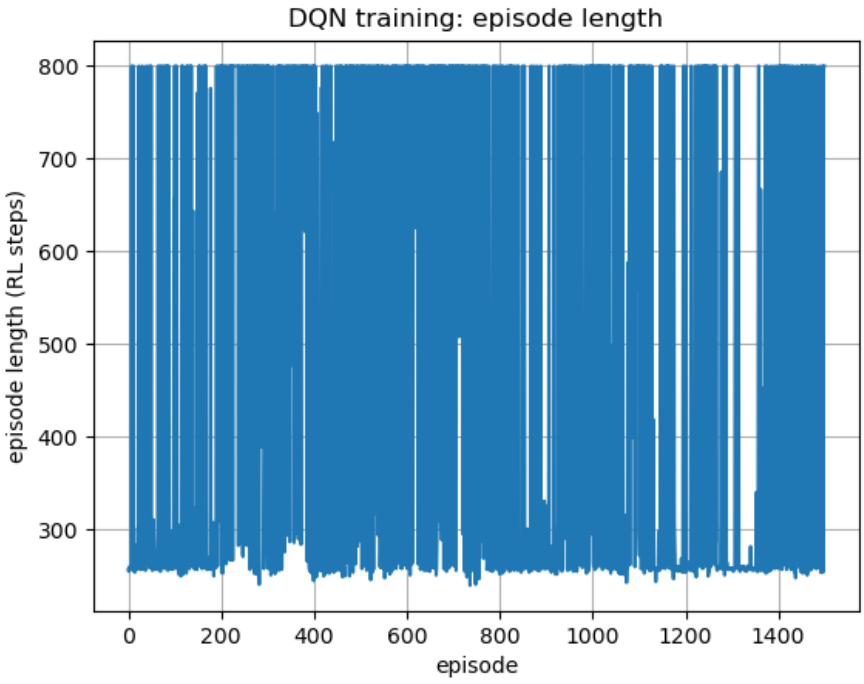
۵ تحلیل نتایج و تفسیر نمودارها (RL)

۱.۵ نمودار پاداش کل اپیزودها



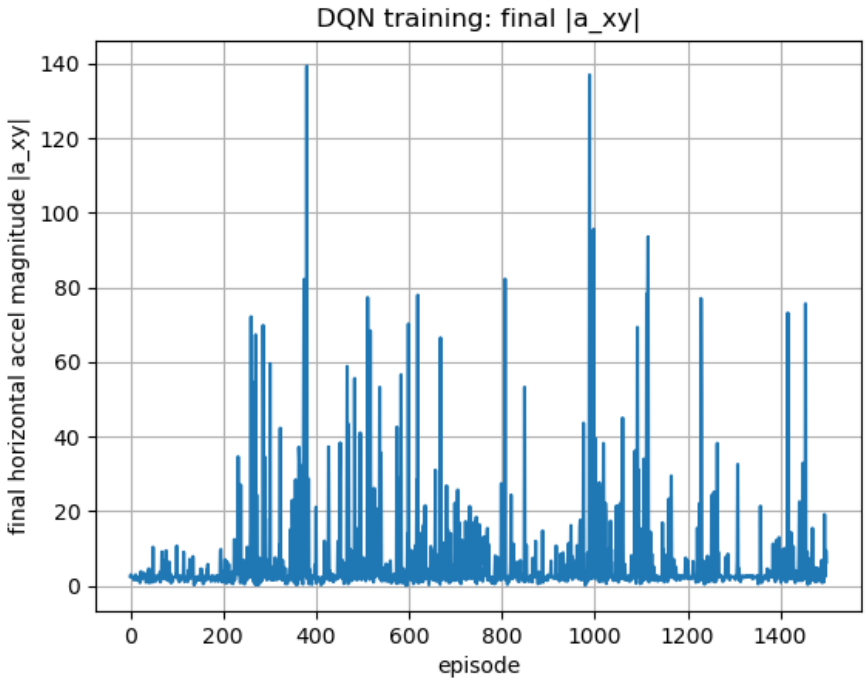
شکل ۲: آموزش DQN: مجموع پاداش در هر اپیزود.

۲.۵ نمودار طول اپیزود



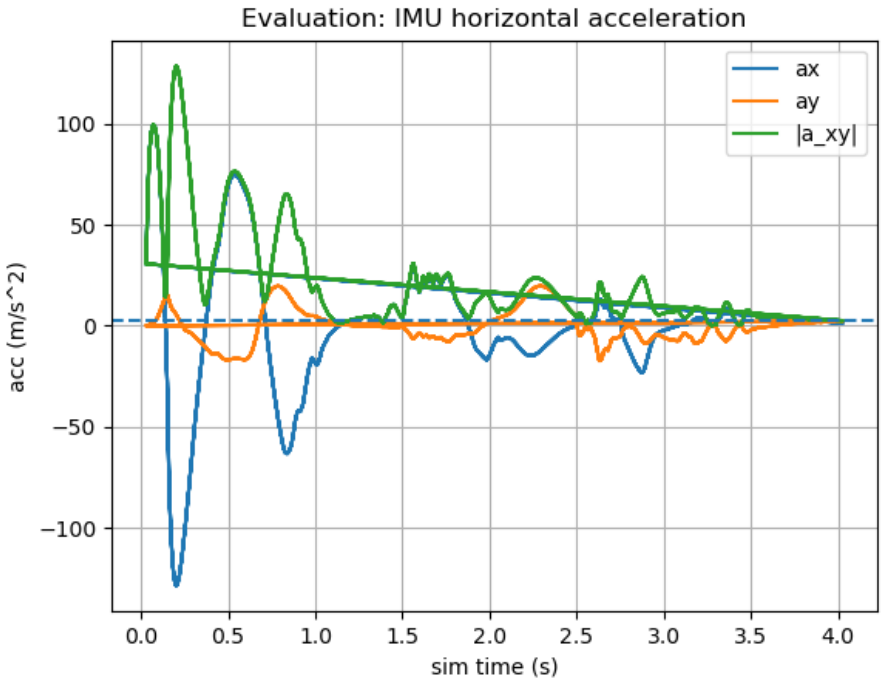
شکل ۳: آموزش DQN: طول اپیزود (تعداد گام‌های RL).

۳.۵ نمودار شتاب افقی نهایی



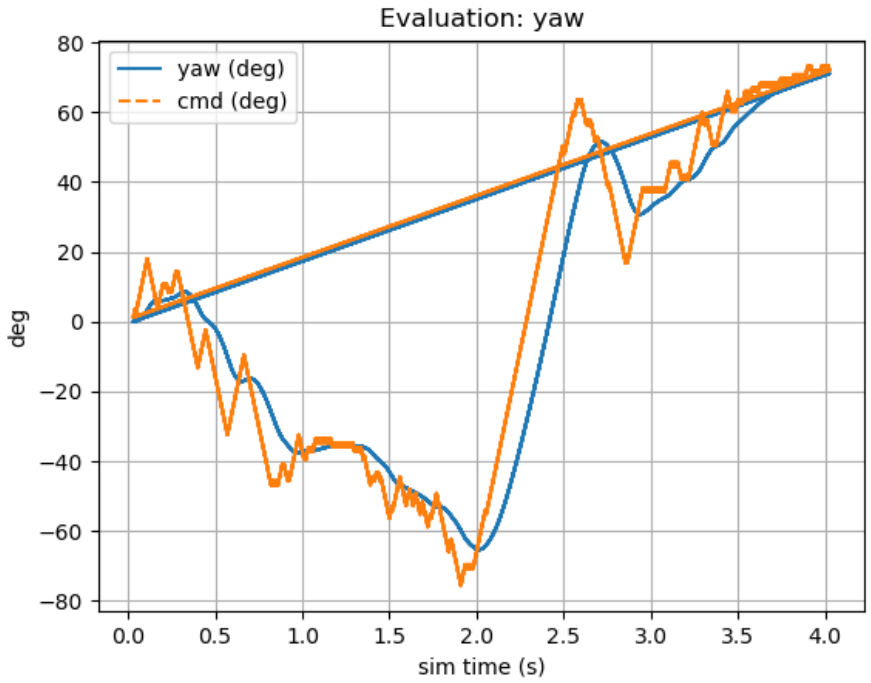
شکل ۴: آموزش DQN: مقدار نهایی $|a_{xy}| = \sqrt{a_x^2 + a_y^2}$ در انتهای اپیزود.

۴.۵ ارزیابی زمانی: شتاب افقی IMU



شکل ۵: ارزیابی DQN: تغییرات زمانی a_x, a_y و $|a_{xy}|$.

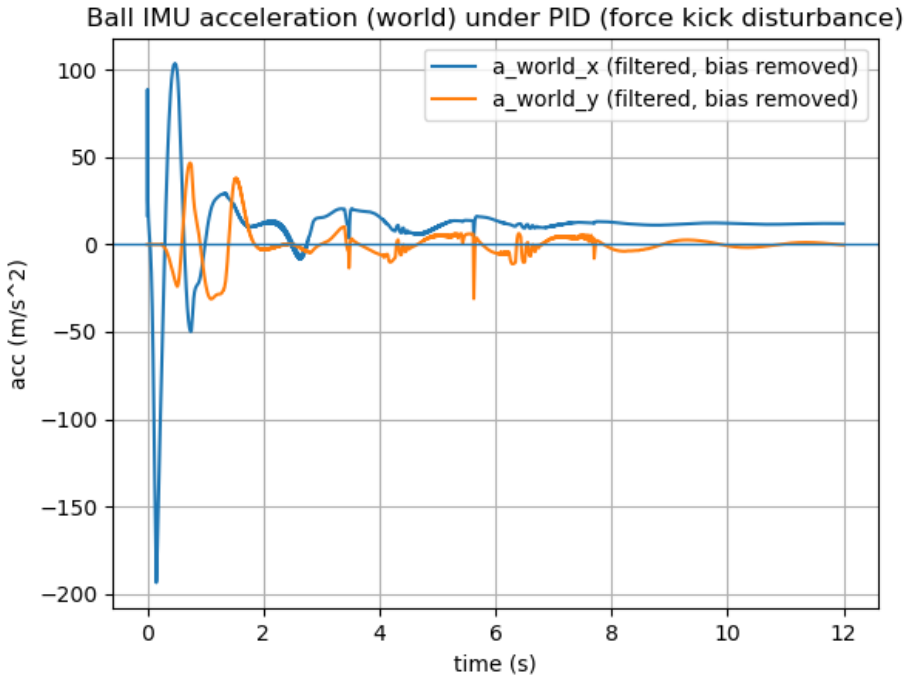
۵.۵ ارزیابی زمانی: یاو واقعی و یاو فرمان



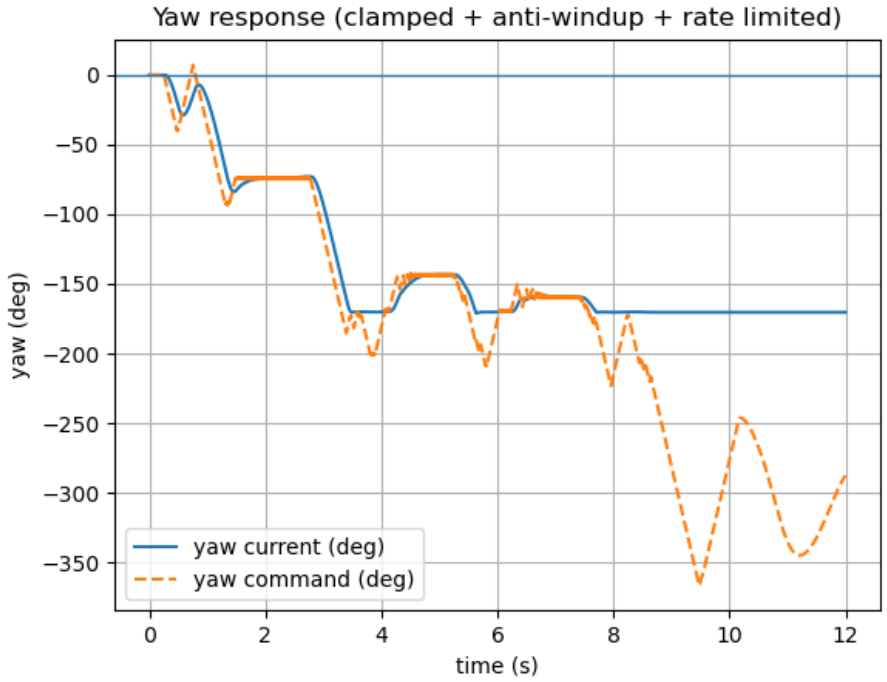
شکل ۶: ارزیابی DQN: یاو واقعی و یاو فرمان.

۶ کنترل PID و تفاوت‌های آن با RL

۱.۶ نتایج PID: تحلیل نمودارها



شکل ۷: کنترل PID: شتاب IMU در چارچوب جهانی.



شکل ۸: کنترل PID: یاو واقعی و یاو فرمان (Clamp + Anti-windup + Rate Limit).

۲.۶ تفاوت‌های کلیدی

- **ماهیت سیاست/قانون کنترل:** PID قانون صریح مبتنی بر خطاست؛ RL سیاست داده‌محور و غیرخطی می‌آموزد.
- **چندبعدی بودن:** PID شما معمولاً یک محور را هدف می‌گیرد؛ RL با پاداش $|a_{xy}|$ هر دو مؤلفهٔ افقی را کمینه می‌کند.
- **اشباع و محدودیت‌ها:** هر دو با clamp/rate-limit روبه‌رو هستند؛ اما RL می‌تواند راهبردهای «زمان‌بندی/فازبندی» را یاد بگیرد.

۷ جمع‌بندی

نتایج نشان می‌دهد کنترل RL پس از ضربهٔ اولیه می‌تواند روند کاهش شتاب افقی را ایجاد کند، اما آموزش نوسان دارد و بخشی از اپیزودها به سقف گام می‌رسند. در PID رفتار قابل پیش‌بینی‌تر است ولی به تیون دقیق بهره‌ها و انتخاب سیگنال خطا (تک‌محوره/دومحوره) وابسته می‌باشد.